TRAVAIL PRATIQUE

Ingénierie des Prompts & LLM (Cloud vs Local)

Programme : 4IASDR | Module : IA Distribuée et SMA | Durée : 1h30

Objectif

Maîtriser les mécanismes de communication avec les modèles de langage (LLM) en utilisant trois plateformes : Gemini (Google), Llama et GPT via OpenRouter. L'objectif est de comparer leurs comportements face à différentes stratégies de prompting et de structurer des données complexes.

Partie 1 : La Porte d'Entrée — La Tokenisation

Question 1.1 — Calcul du nombre de tokens avec tiktoken

À l'aide de la bibliothèque tiktoken, calculez le nombre de tokens pour les deux phrases suivantes :

- "L'intelligence artificielle révolutionne le diagnostic médical."
- "Artificial intelligence revolutionizes medical diagnosis."

Analyse : Le nombre de tokens est-il identique ? Pourquoi la langue française consomme-t-elle parfois plus de tokens que l'anglais pour une même idée ?

Partie 2 : Stratégies de Prompting — Zero-Shot vs Few-Shot

Question 2.1 — Zero-Shot avec Gemini

Configurez un prompt pour classer le commentaire suivant :

« Le nouveau lecteur de glycémie est précis, mais l'application plante souvent. »

Classes possibles : Positif, Négatif ou Mixte.

Contrainte : Ne donnez aucun exemple au modèle. Utilisez l'API Gemini.

Observation : La réponse est-elle concise ou le modèle justifie-t-il trop son choix ?

Question 2.2 — Few-Shot avec Llama via OpenRouter

Utilisez le modèle Llama via OpenRouter pour la même tâche de classification, mais en fournissant trois exemples dans votre prompt.

Objectif : Forcez le modèle à ne répondre que par un seul mot.

Analyse : Le passage au « Few-Shot » a-t-il permis de mieux contrôler le format de la réponse par rapport au Zero-Shot ?

Partie 3 : Cas d'Étude — Extraction de Données Médicales Structurées

Question 3.1 — Prompt Few-Shot pour extraction JSON avec GPT via OpenRouter

Soit la note de consultation suivante :

> *« Examen du 12/05 : Patient rapporte des douleurs thoraciques et un essoufflement à l'effort. Rythme cardiaque rapide. Suspicion d'angine de poitrine. Ordonnance : ECG urgent et repos strict. »*

Mission : Rédigez un prompt Few-Shot pour GPT via OpenRouter afin d'extraire les éléments suivants :

- Les symptômes (sous forme de liste Python).
- Le diagnostic suspecté.
- Les examens et traitements à effectuer.

Contrainte : La sortie doit être un objet JSON pur. Vous devez inclure au moins deux exemples de notes transformées en JSON dans votre prompt pour guider l'IA.